

YOLO 기반 고속축중기 하중 구간 자동 검출 기법

박준영* · 김종우** · 조윤범*** · 정영우****

Park, Jun Young* · Kim, Jong Woo** · Jho, Youn Beom*** · Jung, Young Woo****

YOLO-based Automatic Axle Event Detection for High-Speed Weigh-In-Motion Systems

ABSTRACT

Accurate axle event detection in High-Speed Weigh-In-Motion (HS-WIM) systems is a fundamental requirement for the reliable estimation of individual axle loads and the accurate identification of overweight vehicles. However, conventional threshold-based axle event detection approaches are inherently sensitive to sensor offset drift, environmental noise, and limited responsiveness to low-weight axle loads, which frequently results in false and missed detections. To address these challenges, this study presents an automated axle load segment detection method in which time-series axle load signals acquired from HS-WIM systems are converted into two-dimensional graph representations and analyzed using a YOLOv8-based object detection framework. By learning the characteristic shapes of axle load segments directly from signal representations, the proposed method enables robust axle event detection without reliance on predefined threshold values or absolute signal magnitudes. The proposed model was trained and evaluated using real-world measurement data collected from a public road testbed under actual traffic conditions. The validation results demonstrated high detection performance, with Precision, Recall, and mAP@0.5 values of approximately 0.999, 1.000, and 0.995, respectively. Furthermore, an axle load segment detection accuracy of approximately 95 % was achieved on an independent test dataset. These results indicate that the proposed YOLO-based axle event detection method provides a reliable and practical solution for axle load measurement and overweight vehicle identification in HS-WIM systems.

Keywords : Automated event detection, High-speed Weight-In-Motion, Deep learning, Object detection

초 록

고속축중기 시스템에서 정확한 축하중 구간 인식은 개별 축하중 추정의 신뢰성을 확보하고 과적 차량을 효과적으로 판별하기 위한 중요한 요소이다. 그러나 기존의 임계값 기반 하중 구간 검출 방식은 센서 오프셋 변화, 주행 환경에 따른 노이즈, 저중량 하중에 대한 민감도 부족 등의 문제로 오탐지 및 미탐지가 빈번히 발생하는 한계를 갖는다. 본 연구는 이러한 문제를 해결하기 위해 고속축중기에서 계측된 축하중 시계열 신호를 2차원 그래프 이미지로 변환하고, YOLOv8 기반 객체 인식 기법을 적용하여 축하중 구간의 형상적 특징을 학습·인식하는 새로운 하중 구간 검출 방법을 제안하였다. 제안된 방법은 신호의 절대 크기 변화에 의존하지 않고 하중 구간의 패턴과 형태 정보를 활용함으로써, 다양한 주행 조건에서도 안정적인 검출이 가능하도록 설계되었다. 제안 모델은 공용도로 테스트베드에서 실제 주행 차량을 대상으로 수집된 실측 데이터를 활용하여 학습 및 성능평가를 수행하였다. 그 결과, 검증 단계에서 Precision, Recall, mAP@0.5가 각각 약 0.999, 1.000, 0.995로 높은 성능을 보였으며, 독립적인 테스트 데이터 세트에 대해 약 95 %의 축하중 구간 검출 정확도를 보였다. 이를 통해 제안한 YOLO 기반 하중 구간 인식 기법이 고속축중기 시스템에서 신뢰성 있는 축하중 검출 및 과적 차량 판별에 효과적으로 적용 가능함을 확인하였다.

핵심용어 : 자동 이벤트 검출, 고속축중기, 딥러닝, 객체 탐지

* 정회원 · (주)유디엔에스 개발본부 연구원 (UDNS. Co., Ltd · pjy5451@gmail.com)

** 종신회원 · 교신저자 · (주)유디엔에스 경영본부 사장 (Corresponding Author · UDNS. Co., Ltd · roadload2014@gmail.com)

*** (주)유디엔에스 개발본부 상무 (UDNS. Co., Ltd · jhoyb74@gmail.com)

**** (주)유디엔에스 영업본부 부장 (UDNS. Co., Ltd · youngwoojung83@gmail.com)

Received December 2, 2025/ revised December 9, 2025/ accepted December 11, 2025

1. 서론

도로 인프라에서 과적 차량은 포장과 교량 부재에 과도한 응력을 유발해 피로 손상을 가속하고, 유지관리 비용 증가와 구조적 안전성 저하를 초래하는 주요 요인이다(Park et al., 2024). 이러한 문제를 예방하기 위해 기존에는 주요 도로망에 검문소를 설치하거나 단속 반원이 불시 단속을 나가 의심 차량을 정차시킨 뒤 이동식 계측 장비를 이용해 과적 여부를 확인해왔다(Jacob et al., 2010). 그러나 최근에는 통행 흐름을 방해하지 않고 고속 주행 상태에서 차량의 축하중과 총중량을 계측할 수 있는 고속 축중기(High-Speed Weigh-In-Motion; HS-WIM)가 과적 의심 차량 선별용으로 확대 적용되며, 보다 효율적인 무인·무정차 단속이 가능해지고 있다(ISWIM, 2019).

고속축중기는 센서 종류와 무관하게 차량 통과로 발생하는 하중을 아날로그 신호로 계측하고, 이 신호로부터 유효 하중 구간(valid load interval)을 추출하여 중량으로 환산하는 방식으로 동작한다(FHWA, 2018). 유효 하중 구간 산정에는 일반적으로 임계값(threshold) 기반 규칙(rule-based) 방식이 적용되며, 이는 사전에 설정한 값을 초과하는 신호 구간을 하중 구간으로 정의하는 과정이다(Lorenzen et al., 2022). 그러나 단일 임계값에 의존하는 방식은 오프셋(offset) 변화에 민감하고, 다양한 외부 조건이 존재하는 현장 조건을 충분히 반영하지 못하는 한계를 갖는다. 그 결과, 육안으로는 명확히 식별되는 축 하중 펄스임에도 불구하고 검출되지 않거나, 반대로 축 하중이 아닌 신호가 하중 구간으로 잘못 인식되는 경우가 발생한다.

한편, 신호 처리 분야에서는 딥러닝 기반 객체 인식 기법을 활용해 신호에서 주요 특징을 하나의 객체(object)로 간주해 탐지하려는 시도가 이뤄지고 있다. Kim 등은 구조물의 모달 해석을 위해

R-CNN을 이용해 스펙트럼상의 모드 피크를 자동으로 검출하는 기법을 제안하였다(Kim and Sim, 2019). Jeong 등은 케이블 장력을 추정하기 위해 R-CNN을 이용해 가속도 신호의 고유 진동수를 자동으로 검출하는 기법을 제안하였다(Jeong et al., 2021). 이러한 연구들은 신호값의 절대 크기나 임계값 설정에 의존하지 않고, 신호의 형상(shape)를 객체로 인식한다는 점에서 새로운 분석 방향을 제시한다.

이에 본 연구에서는 고속충중기 시계열 신호로부터 YOLOv8을 이용해 하중 구간을 자동으로 검출하는 방법을 제안한다. 이는 하중 구간이 육안으로는 명확히 식별되는 점을 고려한 것으로, 제안된 방법은 시계열 신호를 객체 인식이 가능한 2차원 이미지로 변환하여 축 하중 구간을 단일 객체로 모델링하여 탐지할 수 있도록 한다. 모델 학습에는 봉동 공용도로 테스트베드에서 수집된 고속충중기 실측 데이터를 활용하였으며, 해당 데이터는 실제 교통환경에서 발생하는 차종 다양성, 속도 편차, 차로 편차, 오프셋 변화, 잡음 수준 변화 등 다양한 환경 조건이 인위적 조작 없이 그대로 반영된 점에서 현실성이 높다. 본 연구에서는 이러한 실도로 기반의 신호를 활용해 모델을 학습하고 성능을 평가하였으며, 안정적인 하중 구간 검출 여부를 확인하였다.

2. 고속충중기 시스템 구성

2.1 고속충중기 계측 원리

고속충중기는 노면에 설치된 축중 센서로부터 주행 중인 차량의 축하중과 총중량을 계측하는 시스템이다. 축중 센서는 로드셀(load cell), 스트레인 게이지(strain gauge), 피에조쿼츠(piezo quartz), 피에조 세라믹(piezo ceramic), 광섬유(optical fiber) 등 여러 타입으로 구현될 수 있으나, 센서에서 출력되는 아날로그 신호를 기반으




Fig. 1. Structure of HS-WIM System




Fig. 2. Signal Processing Workflow for Threshold-Based Axle Event Detection in HS-WIM Systems

로 하중을 산정한다는 기본 구조는 모두 동일하다(Kim and Jeong, 2020). 해당 신호들은 차량이 센서를 통과하기 전에는 일정한 오프셋 수준을 유지하고, 바퀴가 센서를 밟는 순간 발생하는 변형 또는 압력 변화가 전기적 신호로 변환되면서 축하중을 산정할 수 있는 유효 신호 구간(하중 구간)을 형성한다. 센서 타입이나 설치 구조에 따라 발생하는 신호 개형은 상이한데 본 연구는 Fig. 1과 같이 복수의 로드셀이 하나의 열을 이루는 2열 밴딩 플레이트(bending plate) 타입 축중기를 대상으로 한다.

밴딩 플레이트 타입의 본 시스템은 좌우륜을 독립적으로 계측할 수 있도록 두 개의 플랫폼이 좌우에 배치된 구조로, 이 두 플랫폼이 하나의 열을 구성한다. 각 플랫폼은 하단에는 로드셀(LL, LR, RL, RR)이, 상단에는 하중을 전달하는 크로스빔이 배치된 형태로 설계되어 있다. 차량 바퀴가 플랫폼을 통과하면 로드셀에서 발생한 아날로그 신호가 계속되며 이 신호를 처리하여 축하중과 총중량을 산정한다. 구체적인 하중 산정 과정은 Fig. 2와 같다.

고속축중기는 초기 약 1,000 샘플의 평균을 오프셋으로 제거한 뒤, 2차 Bessel 저역통과필터(100 Hz)를 적용하여 고주파 성분을 억제한다. 이후 윈도우 크기 20의 이동평균 필터(moving average filter)로 잔류 노이즈를 제거한다. 전처리된 각 로드셀(LL~RR)

신호는 열 단위로 합산되어 단일 합성 하중 파형을 구성하며, 이는 하중 구간 판정에 활용된다. 유효 하중 구간으로 판정된 영역에서는 구간 내 대표값을 산정하고 스케일 팩터를 적용해 최종 하중 및 총중량을 산정한다. 이와 같이 하중 산정 과정은 정확한 하중 구간 분리 여부에 좌우되므로, 축 이벤트의 시작점과 끝점을 신뢰성 있게 검출하는 것은 아주 중요하다.

2.2 임계값 기반 하중 구간 인식 기법

WIM 신호의 하중 구간 인식은 신호가 임계값을 초과하는 구간을 유효 하중 구간으로 간주하는 규칙 기반 방식이 일반적이다. 이는 단순하고 직관적이며 낮은 연산 능력을 요구한다. 그러나 사전에 정의된 임계값 기반 하중 구간 인식은 다양한 외부 요인이 발생하는 도로 현장에서 여러 문제를 초래한다.

임계값이 낮게 설정되면 축하중이 작더라도 하중 구간을 인식할 수 있다. 그러나 과도하게 낮은 임계값은 Fig. 3(a)과 같이 바퀴 통과 이후 발생하는 오실레이션을 하중으로 오인하거나, 잡음 수준이 높은 현장에서는 노이즈 구간을 축 이벤트로 잘못 인식하는 오탐지(false detection)을 발생하게 한다. 반대로 높은 임계값은 Fig. 3(b)과 같이 진폭이 낮은 축하중을 검출하지 못하고(missing)




Fig. 3. Errors Induced by Rule-Based Threshold Settings. (a) Low Threshold Settings, (b) High Threshold Settings




Fig. 4. Proposed YOLO-based Axle Event Detection Method

detection), 센서 고장 등의 이상치에도 신호 일부를 하중 구간으로 잘못 분류해 낸다. 이는 예외 처리 규칙을 추가해 대응할 수도 있지만, 관리해야 할 예외 유형이 늘어날수록 시스템은 복잡해지고 유지보수가 어려워진다. 또한, 상황에 따라 조절해야 하는 임계값과 예외 처리 파라미터들은 검출의 일관성과 안정성을 저하시킨다.

2.3 제안된 하중 구간 인식 기법

본 연구에서는 임계값 기반의 규칙 기반 하중 구간 인식 대신, 하중 구간을 하나의 이미지 객체로 보고, YOLO를 이용해 비슷한 형상을 찾아내는 하중 구간 인식 기법을 제안한다. YOLO는 2016년 최초로 제안된 딥러닝 기반 객체 탐지 알고리즘으로 one-stage detector 모델 중 가장 대표적인 모델이다. One-stage detector 모델은 객체의 위치와 종류를 동시에 예측하기 때문에, 영역 추정과 분류를 순차적으로 처리하는 two-stage detector에 비해 연산 과정이 단순하고 처리 속도가 빠른 강점이 있다. 초기에는 two-stage detector에 비해 정확도가 떨어졌지만, 모델 구조의 지속적인 개선

을 통해 최근 YOLO 계열은 정확도와 속도 모두에서 경쟁력을 확보하였다(Sosnin et al., 2025). 본 연구에서 제안하는 YOLO 기반 하중 구간 인식 기법은 Fig. 4과 같이 네 단계로 구성된다.

첫 번째 단계는 고속충중기 센서를 통해 차량 통과 시 발생하는 하중을 고속으로 샘플링 하는 것이다. 본 연구에서는 4개의 로드셀이 한 행을 이루는 2열 플레이트 타입의 축중기로부터 데이터를 획득하며 각 로드셀의 신호를 합하여 하나의 축하중을 산정하므로, 1열과 2열에서 각각 하나의 시계열 데이터가 산정된다. 해당 데이터는 원시 신호에서 중량으로 환산하는 캘리브레이션 팩터를 곱한 뒤 필터링을 거친 상태로, 필터링된 개형이 더 일관되고, 시스템 특성상 필터링 된 신호로부터 최종 중량을 산정하기 때문에 이를 적용한다.

두 번째 단계는 고속충중기 시계열 신호를 객체 인식 모델의 입력으로 활용할 수 있도록 2차원 이미지로 변환하는 것이다. 변환 시 축 눈금, 텍스트, 축 라벨 등 비신호 요소는 제거하여 모델이 하중 구간의 형상적 특징만 학습할 수 있도록

하였다. 또한, YOLO 모델은 학습 시 정규화된 경계 상자 좌표 $(x_{norm}, y_{norm}, w_{norm}, h_{norm})$ 를 요구하므로, 이미지 생성 단계에서 경계 박스의 중심 좌표와 폭·높이를 계산 후 전체 이미지 좌표계에 대해 정규화를 수행하였다. 이미지의 좌우 및 상하 경계를 각각 $[x_L, x_R]$, $[y_B, y_T]$ 라 하면, 경계 박스 중심 좌표와 폭·높이는 다음과 같이 정의된다.

$$c_x = \frac{x_{min} + x_{max}}{2}, c_y = \frac{y_{min} + y_{max}}{2} \quad (1)$$

$$w = x_{max} - x_{min}, h = y_{max} - y_{min} \quad (2)$$

YOLO 형식에 맞춰 각 좌표는 이미지 전체 폭과 높이로 정규화되며, $y=0$ 이 상단이 되는 좌표계에 맞춰 다음의 상하 반전을 적용하였다.

$$x_{norm} = \frac{c_x - x_L}{x_R - x_L}, y_{norm} = 1 - \frac{c_y - y_B}{y_T - y_B} \quad (3)$$

$$w_{norm} = \frac{w}{x_R - x_L}, h_{norm} = \frac{h}{y_T - y_B} \quad (4)$$

본 연구에서는 변환된 이미지를 896×296 px의 해상도에 맞춰 모델에 입력하였다. 이는 본 연구의 고속충돌기 신호가 3,125 Hz로 수집되나, 100 Hz 저역통과필터와 20-point 이동평균 필터를 거치

며 5초 구간 기준으로 실효 정보량이 약 500-800 샘플 수준으로 감소하는 것에 기인하였다. 이러한 조건에서 896 px의 입력값은 필터링된 신호에서 형상의 유효 해상도를 과도한 손실 없이 보존할 수 있는 크기로 판단한 것이다.

세 번째 단계는 전처리된 이미지를 YOLO 모델에 입력해 축 이벤트에 해당하는 구간을 경계 상자 형태로 탐지하는 것이다. YOLO는 하중 구간의 높이, 폭, 기울기 변화, 상·하단 형상 등 시계열 펄스가 갖는 국소적·전역적 특징을 통합적으로 분석해 하중 구간 후보를 추출한다. 본 연구에서는 모든 축 이벤트를 단일 클래스로 정의하여 경계 상자의 위치와 크기 회귀에 최적화하도록 학습하였다.

마지막은 탐지된 경계 상자 좌표를 역매핑하여 각 축 이벤트의 시작점과 종료점으로 변환된다. 이후 중복 영역 병합, 주변 노이즈 제거, 경계 보정 등 후처리 과정을 적용하여 최종적인 유효 하중 구간을 산출한다. 이 과정은 임계값 기반 방식에서 빈번히 발생하던 오탐지 및 미탐지를 구조적으로 완화한다는 장점을 갖는다.

3. 학습 데이터 구성 및 전처리

3.1 공용도로 테스트베드 개요

봉동 테스트베드는 지방도 799호선에 설치된 공용도로 실증 구간으로, 익산-봉동 방향 김문소의 사전 선별 지점에 설치되어 2023년부터 현재까지 운영 중인 국내 고속충돌기 현장이다. 해당 구간은 하루 평균 약 7,700대의 차량이 통행하며, 승용차뿐 아니라 2축 화물차부터 6축 트레일러까지 도로교통차량 분류체계에 따른




Fig. 5. Configuration of the Testbed for Evaluating HS-WIM Performance in a Public Road Environment

12종의 차종이 모두通行하여 다양한 주행 데이터를 제공한다. 또한, 차종 외에도 중량, 속도, 차로 편차, 기상 조건 변화, 주야간 환경 등 다양한 환경변수가 그대로 반영되어 현장 활용성이 높은 양질의 데이터를 획득할 수 있다.

3.2 유효 하중 구간 객체 인식 학습용 데이터 세트 구축

고속충종기 시계열 데이터는 옥외합체의 현장 제어기를 통해 각 차량 통과 이벤트마다 개별 파일 단위로 저장된다. 원시 데이터 파일명은 현장 식별자(SiteID), 진행방향(Way), 차로 번호(Lane), 계측 날짜(Loop1_date), 계측 시간(Loop1_time), 이벤트 식별 번호(Loop1_ID), 확장자(extension) 순으로 구성된다.

$$\frac{BD01}{SiteID} - \frac{UP}{Way} - \frac{1}{Lane} - \frac{YYMMDD}{Loop1\ date} \quad (5)$$

$$\frac{HHMMSS.000}{Loop1\ time} - \frac{ID}{Loop1\ ID} - \frac{.tdms}{extension}$$

YOLO를 학습시키기 위해선 학습용 이미지와 이에 대응하는 어노테이션(Annotation) 파일이 요구된다. 어노테이션 파일은 모델 학습을 위한 객체의 클래스 레이블(class_id)과 정규화된 경계

상자 좌표(x_center, y_center, width, height)를 포함하는 .txt 형식의 파일이다(Na et al., 2023). 본 연구에서는 기존 임계값 기반의 규칙 방법을 통해 축 이벤트의 시작-종료 시점을 추출하고, 이를 상자의 좌우 경계로 설정하였으며 해당 구간의 최소-최대값을 위아래 경계로 설정하였다. 다만 경계 상자의 모서리에 항상 신호가 존재하는 패턴을 막기 위해 좌우로는 30 data points, 세로로는 10 px의 마진을 각 박스의 경계에 부여하였다. 시계열 고속충종기 응답으로부터 시작화된 이미지는 896 × 256 px 크기로 시작화되었으며, 배경색, 선두께, DPI는 모든 데이터에 대해 동일하게 적용하였다.

또한 센서 고장 등으로 인식할 하중이 없는 경우를 모델이 구분할 수 있도록, Fig. 6(b)과 같은 부정 샘플(negative sample)도 학습 데이터에 포함하였다. 부정 샘플은 해당 이미지에 대응하는 어노테이션 파일을 비워두는 방식으로 구성하며, 이를 통해 해당 패턴을 탐지할 객체가 없는 배경으로 학습되도록 하였다. 부정 샘플은 전체 데이터 중 총 55개가 포함되었다.

3.3 딥러닝 학습 조건 및 환경

여러 버전이 출시된 YOLO 계열 중 본 연구에서는 YOLOv8을 사용하였다. YOLOv8은 anchor-free 기반의 탐지 구조와 다중 해상도 특징 처리 능력을 갖추어, 폭이 좁고 단순한 형상의 축




Fig. 6. Examples of Training Samples for Axle-Event Detection. (a) Normal Sample with Bounding Boxes, (b) Negative Sample without Bounding Boxes




Fig. 7. YOLOv8 Model Architecture

이벤트를 안정적으로 식별하는 데 적합한 모델이다. 또한 YOLOv8은 비교적 최근인 2023년 출시되어 모델 크기 대비 높은 검출 성능과 빠른 추론 속도를 지니며 다양한 산업/연구에 활용되며 그 안정성이 검증된 바 있다(Lalinia and Sahafi, 2024; Sosnin et al., 2025).

모델 학습은 YOLOv8의 다섯가지 모델 중 속도와 정확도를 고려해 COCO 사전학습 가중치가 적용된 YOLOv8s를 사용하였다. 입력 크기는 896으로 설정하여 WIM 신호의 시간축 해상도를 확보하면서도 GPU 메모리 사용량을 고려하였으며 Batch Size는 8로 설정하였다. YOLO는 학습 과정에서 과적합을 방지하고 일반

화 성능을 확보하기 위해 15개 이상의 데이터 증강(data Augmentation) 옵션을 지원한다. 본 연구에서는 그 중 학습에 유효한 수평 반전(fliplr), 크기(scale), 이동(translate), 혼합(mixup)만 적용하였으며, 학습에 사용한 파라미터는 Table 1과 같다. 기타 증강은 신호 형상을 왜곡하여 학습을 저해하므로 모두 제외하였다.

모든 학습은 Windows 11 환경에서 Python 3.13 버전으로 YOLO를 실행하였으며, Pytorch 2.8.0 딥러닝 프레임워크를 활용했다. 하드웨어는 8코어 16스레드인 Ryzen 7 7800X3D (4.20GHz) CPU, NVIDIA GeForce RTX 4070 Super GPU, 32GB RAM을 사용하였다.

Table 1. Augmentation Parameters

	fliplr	scale	translate	mixup
Value	0.37	0.11	0.03	0.01




Fig. 8. Augmentation Strategies for Enhancing YOLO Detection Performance

4. 학습 결과


4.1 학습 수렴 특성 및 정량적 특성

YOLO 기반 하중 구간 인식 기법의 학습에는 2025년 7월 1일 하루 간 공용도로를 통행한 차량이 활용되었다. 이때, 1종 차량(승용차)은 학습에서 제외하였는데, 1종 차량의 비율이 전체의 66 %를 차지하므로 학습 데이터 분포가 과도하게 편향되는 것을 막기 위해서였다. 이에 따라, 학습에 반영된 총 검지 횟수는 2,959대였으며, 본 연구의 고속측중기가 2열 구조로 설치되어 총 5,918개의 데이터가 모델 학습에 활용되었다.

전체 데이터는 일반화 성능 확보를 위해 학습(train):검증(val):평가(test)=7:2:1의 비율로 무작위 나누어 사용하였다. 모델은 총 100 epoch 동안 학습되었으며, 학습 손실(train/box_loss, train/cls_loss, train/df_loss)은 각각 box_loss $\approx$ 0.09, cls_loss $\approx$ 0.06, df_loss $\approx$ 0.75 수준으로 수렴하였다. 검증 손실(val/box_loss, val/cls_loss, val/df_loss)의 경우 학습 손실과 유

Table 2. Detection Count by Vehicle Type

	1	2	3	4	5	6	7	8	9	10	11	12	etc
Detection	5,939	3	1,191	806	504	307	47	15	0	27	0	4	55

**Fig. 9.** Augmentation Strategies for Enhancing YOLO Detection Performance. (a) Box Regression Loss, (b) Classification Loss, (c) DFL Loss, (d) Precision, Recall and mAP

사하계 $\text{box_loss} \approx 0.11$, $\text{cls_loss} \approx 0.07$, $\text{dfl_loss} \approx 0.85$ 수준으로 수렴하였으며, 학습-검증 간 괴리가 크지 않아 과적합(Overfitting) 경향은 보이지 않았다.

정량적 성능지표를 보면, 정밀도(precision)는 전 학습 구간에서 0.999 이상, 재현율(recall)은 전 구간에서 1.0 유지, $\text{mAP}@0.5$ 는 0.995 수준을 보였으며, $\text{mAP}@0.5:0.95$ 는 학습 진행과 함께 점진적으로 증가해 약 0.994에 수렴하였다. 이를 통해 본 모델이 다양한 하중 크기와 과형 특성을 갖는 고속충돌기 신호에 대해 안정적이고 일관된 하중 구간 검출 능력을 확보했음을 확인하였다.

$$\text{Precision} = \frac{TP}{(TP+FP)} \quad (6)$$

$$\text{Recall} = \frac{TP}{(TP+FN)} \quad (7)$$

4.2 테스트 데이터 세트 기반 성능평가

제안된 YOLO 기반 모델의 일반화 성능을 검증하기 위해 테스트 데이터 세트를 활용한 성능평가를 수행하였다. 예측 결과, 본 학습 모델은 약 98 %의 하중 구간 검출 정확도를 달성하였다. 이에 따라 모델이 차종에 관계없이 축하중 구간을 정확히 감지한 것을 확인하였다. 하지만 본 학습 데이터의 경우 고속충돌기가 정상적으로 감지한 신호를 중심으로 구성되었기 때문에, 모델의 강건성 검증에는 한계가 존재한다. 특히, 하중 구간 검출에 오류를 유발할 수 있는 부정 샘플의 비율이 매우 낮아, 실제 시스템의 잠재적 오류 발생 상황에 대한 모델의 대처 능력을 충분히 평가하지 못하였다. 따라서 향후 모델의 현장 적용 강건성을 확보하기 위해 다양한 유형의 비정상 신호 및 오류 샘플을 수집해 추가적인 성능 검증이 필요하다.




Fig. 10. Performance Evaluation of the YOLO-based Axle Event Detection. (a) Confusion Matrix, (b) False Positive Prediction, (c) True Negative Prediction

5. 결론

본 연구는 고속충충기에서 계측되는 축하중 시계열 신호를 대상으로, 시계열 데이터를 그래프 이미지로 변환하고 YOLOv8 기반 객체 인식 기법을 적용하여 하중 구간을 탐지하는 새로운 방법론을 제안하였다. 제안된 방법은 기존의 임계값 기반 규칙 방식이 신호 오프셋 변화, 잡음 증가, 그리고 작은 축하중 등으로 인해 발생하는 오탐지 및 미탐지 문제를 신호의 형태 기반 객체 인식 접근법으로 극복한다는 점에서 중요한 차별성을 갖는다. 제안된 모델은 실제로 테스트베드에서 수집된 총 5,918개의 실측 고속충충기 데이터를 활용하여 학습 및 성능평가를 진행하였다. 학습 결과, Box, Cls, DFL Loss가 모두 안정적으로 수렴하는 양상을 보였으며, 검증 단계에서는 Precision, Recall, mAP@0.5가 각각 약 0.999, 1.000, 0.995로 매우 우수한 성능지표를 달성하였다. 또한, 학습에 사용되지 않은 테스트 데이터 세트 기반의 검증에서도 95 %의 축하중 구간 검출 정확도를 확인함으로써, 본 연구에서 제안한 YOLO 기반 하중 구간 인식 기법이 고속충충기 시스템에 성공적으로 적용될 수 있음을 입증하였다. 향후 연구에서는 현재 데이터 세트에 부족했던 비정상 신호 및 오류 유발 샘플을 추가로 확보하여 모델의 현장 적용 강건성을 보다 확증할 수 있는 환경에서 성능 검증을 진행할 예정이다. 이를 통해 고속충충기 시스템의 측정 신뢰도를 한층 더 높이는 데 기여할 것으로 기대된다.

Acknowledgements

This research was funded by the Korea Agency for Infrastructure Technology Advancement (KAIA) grant funded by the Ministry of Land, Infrastructure, and Transport under

grant number [RS-2022-00142239].

This paper has been written by modifying and supplementing the KSCE 2025 CONVENTION paper.

ORCID

Junyoung Park <https://orcid.org/0000-0002-3527-8534>
 Jongwoo Kim <https://orcid.org/0000-0001-8175-5816>
 Younbeom Jho <https://orcid.org/0000-0003-2638-9467>
 Youngwoo Jung <https://orcid.org/0000-0001-8207-1619>

References

- International Society for Weigh-In-Motion (ISWIM). (2019). *Guide for Users of Weigh-In-Motion*. Radovljica, Slovenia: ISWIM.
- Jacob, B. and Feypell-de La Beaumelle, V. (2010). "Improving truck safety: Potential of weigh-in-motion technology." *IATSS Research*, Vol. 34, No. 1, pp. 9-15, <https://doi.org/10.1016/j.iatssr.2010.06.003>.
- Jeong, S., Kim, H., Lee, J., and Sim, S. H. (2021). "Automated wireless monitoring system for cable tension forces using deep learning." *Structural Health Monitoring*, Vol. 20, No. 4, pp. 1805-1821, <https://doi.org/10.1177/1475921720935837>.
- Kim, H. and Sim, S. H. (2019). "Automated peak picking using region-based convolutional neural network for operational modal analysis." *Structural Control and Health Monitoring*, Vol. 26, No. 11, e2436, <https://doi.org/10.1002/stc.2436>.
- Kim, J. and Jeong, Y. (2020). "Analysis of the effectiveness of a hybrid weight conversion algorithm for high-speed weigh-in-motion using driving tests." *Journal of Korean ITS Society*, Vol. 19, No. 4, pp. 67-80 (in Korean).
- Lalinia, M. and Sahafi, A. (2024). "Colorectal polyp detection in

- colonoscopy images using YOLO-V8 network.” *Signal, Image and Video Processing*, Vol. 18, No. 3, pp. 2047-2058, <https://doi.org/10.1007/s11760-023-02835-1>.
- Lorenzen, S. R., Riedel, H., Rupp, M. M., Schmeiser, L., Berthold, H., Firus, A., and Schneider, J. (2022). “Virtual axle detector based on analysis of bridge acceleration measurements by fully convolutional network.” *Sensors*, Vol. 22, No. 22, p. 8963, <https://doi.org/10.3390/s22228963>.
- Na, J. H., Shin, H. S., Lee, J. K., and Yun, I. D. (2023). “Building-up and feasibility study of image dataset of field construction equipments for AI training.” *KSCE Journal of Civil and Environmental Engineering Research*, Vol. 43, No. 1, pp. 99-107, <https://doi.org/10.12652/Ksce.2023.43.1.0099> (in Korean).
- Park, J., Kim, J., Kim, J., and Jho, Y. (2024). “Stabilization of dynamic weight estimation systems for commercial vehicles during driving.” *Journal of the Korean Society of Mechanical Technology*, Vol. 26, No. 5, pp. 1041-1046, <https://doi.org/10.17958/ksmt.26.5.202410.1041> (in Korean).
- Sosnin, E. I., Vasilev, Y. L., Solovyev, R. A., Stempkovskiy, A. L., Telpukhov, D. V., Vasilev, A. A., Amerikanov, A. A., and Romanov, A. Y. (2025). “AlphaDent: A dataset for automated tooth pathology detection.” *arXiv preprint*, arXiv:2507.22512, <https://doi.org/10.48550/arXiv.2507.22512>
- United States. Department of Transportation. Federal Highway Administration (FHWA). (2018). *Weigh-in-Motion Pocket Guide: Part 1 - WIM Technology, Data Acquisition, and Procurement Guide*, FHWA-PL-18-015, Washington, D.C.: FHWA.